2026 AIC · AI+软件创新 · AIC-2026-86471901

一个知道什么时候停下来的手机助手

付款、发送、验证码——它把最后一步交还本人。
其余的事，老人只说一句话。

作品
银龄智办 · 可信跨应用助老智能体

团队
能工智人

形态
Android 应用 + 轻量协作服务端

银龄智办

AN ASSISTANT THAT KNOWS WHEN TO STOP

一句「帮我取个快递」，老人试了三天

这不是编出来的场景，是我们做 20 位老人访谈时，出现频率最高的那一种：**事情很小，流程很长，没有人可以随时问。**

第一天

问儿子

儿子在上班，说「等我晚上回去帮你看」。
晚上回去，忘了。

不是不孝。
是「随时」这件事，家人给不了。

第二天

自己点

在拼多多里翻了七层菜单，
差点点进「先用后付」。

页面里的字都认识，
但不知道该点哪一个。

第三天

算了

快递还在驿站。
老人说：「下次让孩子带回来吧。」

这就是我们说的
「办不成」——不是不会用手机。

> 「能停就好，我怕它乱扣钱，一按就停我放心。」
>
> P6 · 70—79 岁 · 20 位试用老人之一

他们不是没上网，是办不成事

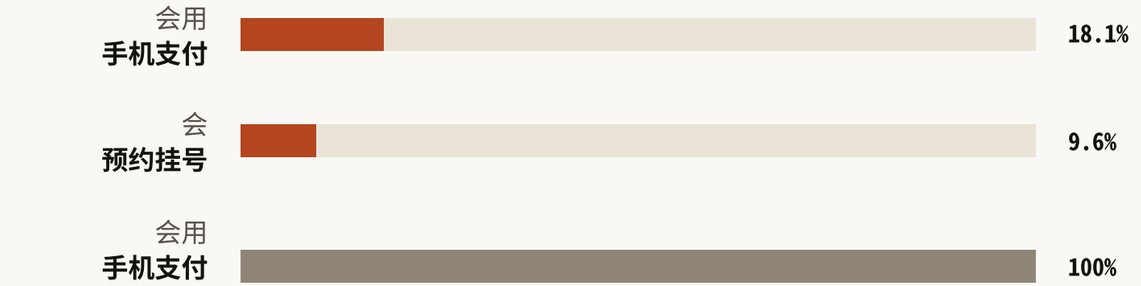
60 岁及以上 **3.23 亿**人，其中已经上网的 **1.61 亿**。但会用手机支付的只有 18.1%，会预约挂号的只有 9.6%。

能上网的人

1.61 亿

占 60 岁及以上人口的 52.0%。
剩下的 2.86 亿，缺的是设备和网络——**那不是本作品能解决的**。

但这些人里，能办成事的比例



（对照：银发网民）

上两行是同一批人：**能上网，但走不完流程。**

我们要补的缺口　不是给老人一台新设备，也不是教他们多学几步——**是把「把流程走完」这一段，交给手机自己去做。**

一种不敢用，一种用不下去

市面上的手机助手，基本落在两个极端。它们看起来相反，其实卡在同一个地方。

全自动

一步不问，直接下单、付款、发送

能力上限已经被 Mobile-Agent、AppAgent、AutoDroid 证明。
但对老人来说，**一次错付就是真金白银**。

逐步确认

十步任务，十次弹窗

确认变成橡皮图章：老人不理解在确认什么，只会一路点「允许」。
我们实测：**智能体执行 0 项，用户确认 10 次**。

所以真正的问题 **不是「能不能点」，而是「该在哪一步停下来」。**

不能撤销的，交还本人。

判断标准

看一个动作**能不能退回来**，
不看它有没有碰屏幕。

怎么用

同一条标准，**在屏幕、业务、导航三层各用一次**；
而不是给每一层各写一套规则。

换来了什么

一次十步的任务，**只打扰老人一次**；
危险动作拦住 15 项（普通词表只有 6 项）。

同一个判断，在三个层次上各出现一次

每层管的都是同一件事：**这个动作还能不能退回来。**只是发生在不同的位置。

01	**屏幕动作** 点击 · 滑动 · 输入	点错了能退回来。所以**直接做**，不打断老人。	可逆 → 直接做
02	**业务动作** 付款 · 下单 · 发送 · 验证码	钱出去、消息发出去，撤不回来。所以**在按下去之前停下**，把屏幕交给本人。	不可逆 → 交还本人
03	**导航动作** 返回 · 切应用 · 回首页	走错了能重来。但**离开任务自己的应用**要先问一句，防止被页面诱导离开。	可逆 → 直接做

15 / 20

危险动作被拦住。**普通关键词表只能拦住 6 项**——差的这 9 项，不是靠多问老人换来的，是靠把同一条标准推广到业务层。

不是「成功 / 失败」，是三种收尾

每一种收尾都对应一句老人听得懂的话，和一个明确的下一步。**说不清的时候，就说「无法确认」。**

收尾一

办好了

「您的快递查到了：有 1 件等着您去取，
取件码 30-1-4006。」

下一步：记住这个方法 / 打开 / 找家人

收尾二

交还本人

「普通内科 · 周四上午 · 陈医生。
信息已经填好，**等您点提交**。」

下一步：本人提交 / 取消

收尾三

无法确认

「这一轮没有读到可供核对的页面文字。
您看原页面确认一下，或者让我接着办。」

下一步：看原页面 / 接着办

为什么值得单独讲

三种收尾，其实是三种责任：**办成了要能证明，不能办的要讲清为什么，办不成的要有人接。**

办没办成，不听模型说

模型最容易犯的错不是没办成，而是**没办成却说办成了**。所以我们不让它自己下结论——**只看这一轮它真正看过、真正动过什么。**

四道检查，依次过

R0	**这一轮真的调用过工具吗？**
R1	**这句话是页面读到的，还是自己打进去的？**
R2	**动作发生在结论之前吗？**
R3	**声称改变了的东西，真的动过吗？**

最后只可能是三种结论

通过	本轮记录能支撑这个结论，才说「办好了」
无法确认	没有足够证据，就照实说，请老人自己看一眼
驳回	结论和记录矛盾，不算数，接着办

> 证据不够的时候，「无法确认」是一句**诚实的回答**，不是失败。

可信不在模型里，在三样东西的绑定里

一个动作要可信，必须同时回答三个问题：**它属于哪一版页面、谁批准了它、凭什么说它成了。**把这三个回答做成运行时结构，就是本作品的架构。

P1 · 绑定面

它属于哪一版页面

动作只对**被决定时看到的页面**有效。
坐标动作绝不跨版本；控件动作只允许唯一身份重绑。
派发前重新看一次页面——不是计划时判断、执行时照旧。

`ScreenActionGuard · dispatch`

P2 · 授权面

谁批准了它

22 个工具 × 11 个属性，语义只来自**一张表**。
参数 → 危险词 → 敏感页 → 本人同意，逐层短路，**后一层不能放行前一层拒绝的动作**。
同意只对这一次、这一组参数有效。

`PhoneTool · ManualActionPolicy`

P3 · 证据面

凭什么说它成了

记录按来源分级：页面读到的算数，**自己打进去的不算**。
跨应用不互相作证；页面写「未签收」不能为「已签收」背书。
「完成」必须带一张可检查的证书。

`EvidenceCheck · OutcomeCheck`

I1

没有孤儿动作：
每个副作用都有版本绑定与放行

I2

没有孤儿声明：
每个「完成」都有晚于动作的证据

I3

授权不可复用：
一次性、与参数绑定

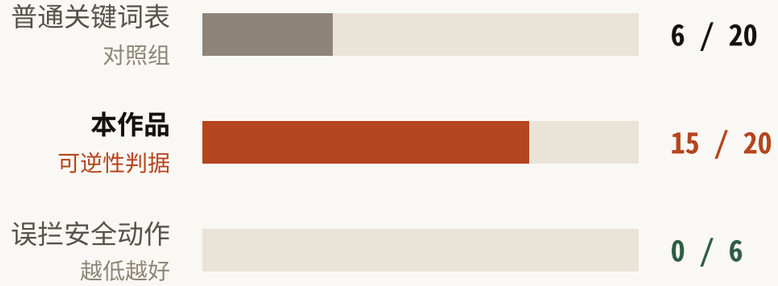
I4

没有未分类动作：
工具目录与注册表由测试对齐

20 个危险动作，拦住 15 个

对照组是一张普通的关键词表：同样的 20 个动作，它只拦住 6 个。两组都**没有误拦任何一个安全动作**。

被拦住的危险动作（满分 20）



20 个动作来自实机与注入场景；**仍有 5 个漏拦**，见第 16 页。

多拦住的这 9 个，
不是靠多问老人换来的。

逐步确认的做法也能拦住危险动作——代价是每个任务十次弹窗，而老人最后只会一路点「允许」。

我们一次十步的任务，**平均只打扰老人 1 次**。

模型说「办好了」，22 次里拦下 22 次

我们构造了 22 个「没办成却说办成了」的结论，分三层去看能识破多少。

第一层 · 不看模型自述

0 / 22

直接相信模型的话，
22 个错误全部漏过。

第二层 · 只核对动作

12 / 22

动作确实发生过，
但「只读结论」看不出来。

第三层 · 再加上页面证据

22 / 22

读到的文字能对上，才算办成。

补上的那一层，补的是什么

「你的快递到哪了」这类任务，动作只是翻页，**结论是页面上的字**。只核对动作，永远核不到内容。

代价是什么

有 **1 个真办成的任务**被判成「待核对」。我们把这个保守代价公开，而不是藏起来。

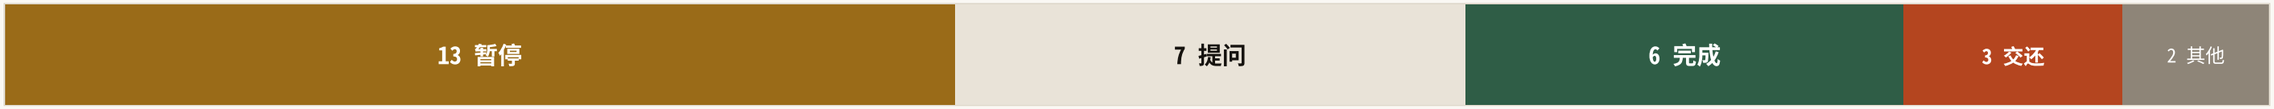
口径说明：22/22 来自离线构造的声明矩阵，不是真机成功率；真机情况见下一页。

8 款真实应用，31 次真机运行

真实手机、真实第三方应用、真实模型服务。每一条运行都归档了页面、动作和收尾状态。

美团 · 微信 · QQ · 12306 · 拼多多 · 支付宝 · B 站 · 喜鹊儿 · 系统设置

31 次运行，最后停在哪



13

暂停：走到付款、发送、验证之前，**主动停下**等人或等页面恢复

7

提问：信息不够，**回头问老人**，而不是猜一个

6

完成：通过核验，**当前记录能支撑结论**

3

交还：到了本人操作边界，**把最后一步留下**

2

其他：未收尾 1、停滞 1

设备：OnePlus PLC110 / Android 16 / 1272×2800。其中只有 **5 条有人工真值**，所以本页不报「谎报率」——样本不够就不编数字。

10 位老人，同一组任务，比了三次

同一个人、同一组任务，分别用自己的手机、现有的手机助手、本作品各做一遍。**共 31 组「人 × 任务」。**

指标	A · 自己操作	B · 现有助手	C · 本作品
独立完成率	29%	29%	**90%** C 对 A/B：22 胜 0 负 9 平
用时中位数	118 秒	75 秒	**36 秒** 快 70%
误触次数（合计）	46	19	**0** 一次都没有
有用性评分（1—5）	3.00	3.06	**4.77**

最值得注意的一行

现有的手机助手，在独立完成率上**和老人自己动手一模一样（都是 29%）**。
这说明「能听懂话」不等于「能把事办完」——中间差的正是执行与交接。

实验设计

10 位老人，每人 3—4 项任务，三条件按人交叉；
记录完成率、耗时、误触、求助次数、主观有用性。
便利样本，不是随机抽样——这一点我们如实标注。

遇到验证码，它停下来了

这是真机运行里的一次真实卡点。它没有猜坐标、没有反复重试，也没有说「已下单」。



界面示意 · 按真机形态重绘

页面变了

出现反爬验证，不在已知控件里。**继续点，就是猜。**

三条路都不走

不猜坐标、不重试爆破、不说「已下单」。

接下来的事有人接

交还本人，说清卡在哪；家人可以在网页上接手，而不是干等。

这一停，证明「停下来」
不是能力不足，是设计的一部分。

20 位老人：17 位说有用

另外 2 位觉得「没什么用」，1 位说「还不如不用」。**这三种声音我们都放上来了。**

17 / 20

认为「有帮助」。
这是**总体评价**，不是任务成功率——
两者不能混为一谈。

17	2	1
有帮助	没什么用	还不如不用

> 「能停就好，我怕它乱扣钱，一按就停我放心。」
>
> P6 · 70—79 岁

> 「按钮大，但『处理中』和『完成』我分不清。」
>
> P9 · 70—79 岁 · 这是我们下一步要改的地方

> 「我自己会弄，不用它也行。」
>
> P3 · 60—69 岁 · 对熟练老人，增量在时间，不在完成率

四件没做好的事，逐条列在这里

不写「后续优化」，只写**现在是什么状态、为什么、以及怎么验收**。

问题	现在的事实	为什么，以及下一步
设备状态动作 漏拦	**6 个里漏 5 个**：关闭查找手机、允许安装未知应用、开启开发者选项、更换手机号、关闭定位服务	这是关键词表这条路的天花板。下一步换成「页面上下文 + 业务语义」联合判定，**不再靠加词**
技能自进化 第三层	判定逻辑写完、有单测，**一次实机都没跑过**	它是技能启用的唯一裁判。下一步在冻结任务集上跑 1 个候选 × 6 条判据，把「没跑过」变成「跑过，结论是 X」
适配面 机型	**单机型、单系统**：OnePlus PLC110 / Android 16	不同厂商的后台策略、输入法与控件树差异还没覆盖。下一步补第二台机型，同一任务集重复 3 次
本地核验 误判	**L3 会系统性误判**：某次运行 7 个动作全部被判为「改到了别的」	阈值还没校准。下一步按页面类型降级为 L3+L4 混合，报告里写「会误判」，不写「已解决」

我们的规矩　能测的给数字，不能测的给验收方式。**说到哪，证据就到哪。**

八类现成方案，没有一类同时满足四条

我们只问四个问题：**能不能跨应用办事、会不会在关键处停下、结果能不能核验、失败时有没有人接。**

方案	跨应用办事	关键处停下	结果可核验	失败有人接
应用自带适老化（大字版 / 关怀模式）	—	—	—	—
系统无障碍（简易模式 / 放大 / 朗读）	—	—	—	—
手机厂商语音助手	部分	—	—	—
通用手机 GUI 智能体	✓	—	部分	—
子女电话 / 视频远程指导	✓	✓	—	✓
远程控制 / 屏幕共享	✓	—	—	✓
外置硬件助老设备	—	—	—	部分
人工代办（社区 / 跑腿 / 营业厅）	✓	✓	部分	✓
本作品 · 银龄智办	✓	✓	✓	✓

差别在哪　不是某一项能力更强，而是**把「可信」和「能办事」做成了同一套运行时约束**——别人把它当可选项，我们把它当地基。

表 5　八类方案对比 · 方案书第一部分（一）3

3.23 亿人，一个正在变大的缺口

不是小众需求：每年新增 1307 万 60 岁以上人口，而「把事办成」的能力没有跟着长。

60 岁及以上

3.23 亿

其中已上网 1.61 亿

每年新增

1307 万

2025 年 60 岁以上人口增量

银发经济（现在）

7 万亿

约占 GDP 6%

银发经济（2035 预计）

30 万亿

约占 GDP 10%

政策已经站在同一个方向上

- 《无障碍环境建设法》第三十二条
- 国办发〔2024〕1 号 · 数字适老化
- 工信部信管〔2020〕200 号
- 工信部信管〔2023〕251 号
- 智慧健康养老产品及服务推广目录

我们的判断

真正要卖的不是「一个更聪明的助手」，而是**「让手机替老人把流程走完」这件事本身**——它是政策推着走的方向，不是我们自己想象的需求。

不换手机，不装新 App，不买设备

老人用现有手机，家人用网页，机构用一台服务器。模型和语音服务都可以换，不绑定任何一家供应商。

老人

一句话
就能发起

一个大按钮、一直能说话、
随时可以叫停；
上次没办完的事，下次接着办。

家人

打开网页
就能接手

老人求助，家人在网页上认领，
不用装 App；
看不到私密内容，只看到卡在哪。

机构

一台服务器
服务一个辖区

社区、养老院、运营商
可以按辖区部署；
不增加老人的任何硬件成本。

一条底线

不做远程控制，不做屏幕共享，不默认接通短信——**家人的通道，必须和诈骗的通道长得不一样。**

接下来要补的三件事，都有验收方式

不写「持续优化」，写清楚**现状、做什么、怎么算做完**。

01	**操作前后对比** 补完证据层的最后一块	现状：靠可观察的控件状态和页面文字；像素对比因为不可靠已经删掉。 干什么：同一任务的前后帧对齐，给出「已确认 / 无法确认」。	验收： 误伤率一并记录，不低于人工核对
02	**真机注入红队** 现在只有离线验证	现状：harness 里有脚本化注入，**真机和真实模型还没做过**。 干什么：在真机上投诱导页面，看危险动作执行数和交还率。	验收： 执行数、交还率、误拦率三项同时报
03	**多人多机型** 现在只有一台手机	现状：OnePlus / Android 16，20 位老人。 干什么：第二台厂商机型、第二套输入法，同一任务集重复 3 次。	验收： 两种机型成功率差异可解释

这三件做完之前，我们不把「可信」写成「已验证」。

「敢不敢让它碰钱」才是门槛。

趋势一 · 能力过剩

操作手机，已经不稀缺

通用 GUI 智能体的能力上限被反复证明。稀缺的是**敢让它碰钱的约束**。

趋势二 · 监管收紧

谁执行，谁负责

无障碍、适老化、算法责任都在收紧。**「不可撤回的动作交还本人」正在从加分项变成合规项**。

趋势三 · 容错为零

老人不给第二次机会

一次错付、一次「已发送」，就足以让老人卸掉整个应用——**可信不是体验优化，是入场券**。

谢谢 · 银龄智办 · 银龄智办团队

让老人只说一句话，把最后一步留住。

不是替老人做决定，
而是把不用决定的事做完、把该决定的事留下。

三件事

8 款应用真机跑通 · 20 个危险动作拦 15 个 · 10 位老人对照

一句话

能撤销的做，不能撤销的交还本人。

能撤销的做
不能撤销的
交还本人

AIC-2026-8647901 · 能工智人