



2026 AIC · 算法创新赛 · AI+软件创新

银龄智办

老人只说一句话，
手机替他把事跑完

真机已跑通 13 项任务 / 8 款第三方应用

团队 能工智人 | 编号 AIC-2026-86471901

老人要办的事，往往就是这一句话

“看看我的快递到哪了”

这是我们在真机上跑过的真实任务输入。
没有 App 名称，没有操作步骤。

而它并不是每次都走得通

同一句话，拼多多与淘宝各 5 步跑通；京东 2 步就停下：“这一步总是做不成，已停下。”



上图为团队真机测试截图；截至提交尚无老年用户试用数据（见 P10）。

问题

不是没有 AI 会点外卖， 是**没人敢**让 AI 替老人点

谎报

说已发送
其实没做成

越权

替老人
点了付款


僵化

卡住就停
或空转到底

“已帮您把消息发出去了……发送成功”——真机原话。
而它只是读到了**本轮开始前就存在**的旧消息。

我们的答案

我们把“可信”从提示词里搬进了架构里



闸门·只看动作内容

不看模型说了什么，也不看它是否被说服

账本·只看执行记录

完成与否不由模型自述，也不交给第二个模型打分

只读·树只作观察

来源再“可信”，也不因此放行

一个圆钮， 一句话

一屏只有一件事。圆钮既是**状态**也是**开关**。

- 只有“不再请求工具”才算完成；“做不到”与“已完成”并排
- 家人只能看状态、领求助、留言——不提供远程控制

● 我在



点一下开始说话

上次没办完的事
看看我的快递到哪了

接着办这件事

全篇唯一记忆点

AI 说办好了**不算数**—— 只有手机上**真的发生的动作**才算数

判据：动作的后果能不能撤销 · 核验：查本轮自己的执行记录，不查模型的说法

13 项真机任务、149 条断言、五组对抗实验

8₊₁

第三方应用 + 系统设置
共 9 个页面跑通

13

真机任务
查票 · 点餐 · 取件 · 缴费

0

美团 10 步点餐
全程打扰次数

149

回归断言
每次改动 2 秒全绿

五组对抗实验：**发现 5 处问题，修复 4 处**，回归断言 **99 → 149**。

第 5 处（词表对边界动作的天花板）**我们没修，也没藏**——见 P10。每一次运行的原始输出（含修复前）逐级留档，报告里每处“修复前/修复后”都能翻到对应记录。

别人靠模型的自律，我们靠架构的兜底

同一个问题	常见做法	我们的做法
谁来判定危险	更强的模型 + 更细的提示词 + 事后过滤	本地闸门只读动作内容——不读模型说辞
谁说了算“办成”	采信模型自述，或再叫一个模型来打分	本轮自己的执行日志——查账不查嘴
卡住了怎么办	重试到底，或直接失败	五种收尾各有界面：做不到 ≠ 已完成，失败能接真人
家人的通道	远程协助 / 远程控制	不做远程控制——从产品形态上排除这条诈骗通道

我们不声称在模型能力上领先。我们主张的是：安全属性应该由架构保证，而不是由模型的顺从保证。

改变的**不是**“能不能上网”， 是**能不能自己办完一件小事**

而不必等子女下班、不必反复打电话问“那个码在哪”。

政策指向

国办发〔2020〕45号、工信部专项行动、《无障碍环境建设法》——**都指向“让老人真正用得上”**

落地形态轻

不换手机、不换 App、零学习成本；家人端零安装

可复制

不绑定具体应用，新增 App 无需改造对方

这三件事，我们现在 还不敢让它做

边界动作拦不住

「关闭查找手机」「退出登录」这类文字中性、后果不可逆的动作，词表**6/6 漏拦**。这是“词表匹配”这条路线的**天花板，不是实现缺陷**。下一步要靠页面语义而非词表。

高动态页面会失败

含常驻轮播的首页（如京东）会让页面版本校验持续判为过期，**2 步即耗尽修复预算**而暂停。同题在拼多多、淘宝成功，说明是**间歇性的**——而间歇性失败对老人更难理解。

还没有一位真实老人用过

现阶段完成的是实验室与团队内部的高仿真任务走查。**零老年用户数据**是我们最大的缺口。最小可用性观察（知情同意 + 3 类任务 + 四项指标）已在筹备。

下一步

先补上人，再补上证据层

1 · 老年用户观察

5-8 位老人、知情同意、3 类任务，记录四项：能否**独立发起** / **理解状态** / **中止** / **找到真人**。这一项同时抬“应用价值”与“功能完整性”。

2 · 证据层核验接入主流程

我们已经在回归套件里做出了原型并量化过它（识别谎报 4/5 → 5/5，代价 1/4 → 2/4），下一步是给它一个能区分“**页面上没有**”与“**事情没发生**”的判据，然后接进执行循环。

3 · 动态页面与技能闭环

把页面版本校验与修复预算解耦；完成技能自进化的完整闭环（失败归因、独立任务验证、按版本自动选版）。



技术的终点， 是让老人不必学会技术

把“可信”做成**架构约束**，而不是提示词里的请求。

银龄智办·可信自进化跨应用助老智能体

团队 能工智人 | 参赛编号 AIC-2026-86471901

一致。第三部分（四）与附录代码段均描述现行实现；附录代码为**逐行取自** `AgentLoop.kt` 的节选（27 行有效代码全部可在仓库检索到）。

- 现行机制：**动作周期**（窗口 12，尾部按周期 2~3 完整重复 3 次且含 ≥ 2 种工具）+ **无效重复**（同工具同参数且 `screenChanged` 恒为 false）
- 停止条件：动作循环提醒 5 次、无效重复提醒 3 次 / 停止 5 次
- **刻意不用页面指纹**：真实应用会动画、重算价格、轮播推广，指纹会产生假重复；翻页而文本不变同样会漏判

放弃指纹不是退让：把“什么算进展”建立在一个在真实应用里不成立的假设上，比不做这项判定更危险。

证明

给定一个**会撒谎、会松口、会绕路**的模型，闸门与核验逻辑本身的**确定性**——它不随模型的说辞变化。

不证明

真实模型被注入说服后也一定拦得住。后者取决于模型能力，属于模型侧变量，不是架构侧的保证。

真实模型由谁负责

第五部分 13 项真机任务（真实模型 + 真实第三方 App）与第七部分跨应用验证。

完整证据链

受控实验证明架构成立，真机实验证明在真实模型与真实应用上可用。

凡对抗实验结论，均按“有对照 / 可复现 / 有守护”三条标准标注成立条件，不外推到真实模型的安全性上。

F5 是**路线级上限**，不是实现缺陷。词表匹配能可靠拦住**有明确危险文字**的动作，但拦不住“文字本身中性、后果不可逆”的边界动作。

类别	结果	示例
显性危险动作	6 / 6 拦住	确认付款、立即支付、提交订单
隐蔽型危险动作	8 / 8 拦住	申请退款、取消订单、恢复出厂设置
边界探针	6 / 6 漏拦	关闭查找手机、允许安装未知应用、开启开发者选项、退出登录、更换手机号、关闭定位服务

如实保留比虚假承诺更有价值：**我们不用“漏拦率 0”这类把“模型无能”算作“安全有效”的表述。**

- **只发当前页面的可见文字与控件结构**，用于规划；不采集通讯录、相册、通话记录、麦克风常驻录音。
- **输入类动作的正文**由本地闸门先筛本人操作词表，命中即拒绝并交还本人，不进入模型决策。
- **截图按需**：仅在控件树缺失（纯图页面）时附加，且**每页只发一次**。
- **只追加、不重写**的对话记录保存在本机；任务存档可随时删除。
- **已知不足**：尚未按应用排除敏感页面（如银行类页面整体排除），这是下一步要做的事。

已经交付：候选生成 + 人工采用/回退

成功任务可沉淀为**候选技巧**；候选先进入候选区，由家人在设置页**采用后才会出现在** `load_skill` **可用列表中**，可随时回退。技巧只存文字步骤，不存截图，也不自动生效。

尚未交付：自动闭环

失败归因、独立任务验证、按版本自动选版——属第八部分列明的研发方向，目前状态为**拟研发**。

因此“自进化”在当前版本中的准确含义是：**技巧可以沉淀、可以复用、可以回退，但采用与否由人决定**——这也是我们把它做成一等公民而非黑箱的原因。

同一目标“看看我的快递到哪了”，拼多多与淘宝 **COMPLETED**（各 5 步），京东 **PAUSED**（2 步）。

机制解释：stale_screen 版本校验是**为安全而设的竞态防线**（防止动作作用于已过期的界面观察），但在含常驻轮播的高动态首页上，界面版本高频变动使合法动作被判为过期，**在 2 次修复预算内即耗尽配额**。

- 同类电商首页在拼多多、淘宝成功 → 该失败是**间歇性**的
- 对老人而言，**间歇性失败比确定性失败更难理解**——这正是它值得单独记一条的原因
- 改进方向：把 stale_screen 与常规修复预算解耦，或改为自动重观察并重解析同一语义目标（新发现 F6，尚未修复）

最可能被问的第一题 · 不要绕

目前还没有。 这是我们知道的**最大缺口**

不掩饰

我们把“适配性强”明确标注为**待验证假设**，不当作已完成事实；材料里所有涉及用户的地方都标注了“尚无正式试用数据”。

已设计好验证

对象：5–8 位老人，经学校离退休工作处 / 社区渠道招募；任务式测试（非满意度问卷）；四项指标：**能否独立发起 / 理解状态 / 中止 / 找到真人**。

手上有非用户证据

真机 13 项任务、8 款应用、149 条断言、五组对抗实验——这些是**工程证据**，不是用户证据，我们不混为一谈。

这也是我们答辩后要做的**第一件事**，不是可选项。

“一些适老化改造**流于形式，精准适配不足**。如，部分 APP 适老化改造**仅停留在‘大字、大图标’的调整**。”

—— 国务院发展研究中心《持续提升数字技术适老化水平》，《经济日报》2026-03-22

长辈模式改的是看得清——字号、图标、对比度

我们替老人完成的是办得成——跨应用的流程执行本身

作用层级不同不是把界面改简单，而是把“操作”这件事从老人手里拿走

这一击有官方智库背书，且不需要任何用户数据。

这是**最危险的一问**——若被认定为“核心功能缺失”，功能完整性会从“次要功能不完善”掉到最低档。必须正面、具体地回答。

已做到哪一步

机械层核验

(OutcomeCheck) **已上线**；
证据层核验已在回归套件里做出**可运行原型**，并用三组对照量化过：识别谎报 4/5 → 5/5，代价 1/4 → 2/4。

为什么没有直接接进去

原型的误伤样本（“汇总计算得出、页面上没直接出现”的**数字被降级**）是我们主动放进对照的。在老年场景里，把**真办成的说成“无法确认”**同样是伤害——接进去之前必须先解决这个判据。

接入的判据与时间表

判据：能在页面上区分“**没有**”与“**没发生**”。路径：先做只读结论的前后帧比对，再逐步扩展到改变类动作；**后台比对能力分批上线，每一步由回归断言守护。**

我们宁可现在把“没接进去”说清楚，也不在答辩台上说一句我们自己验证不了的话。

按清华 x-lab 的提醒，不做“全面碾压”式对比——那是硬科技路演五大误区之一（竞品失真）。

优化的目标	通用 GUI Agent	银龄智办
优化什么	平均任务成功率	误操作率与可恢复性
失败了怎样	重试到步数上限	五种收尾各有界面，失败能接真人
不做什么	—	不提供远程控制（形态上排除诈骗通道）
对谁负责	发出指令的人	使用手机的老人与不在场的家人

我们不需要在模型能力上领先，只需要在“老人敢不敢把手机交出去”这件事上领先。

第一步 · 点位试点从学校离退休工作处 / 关工委、社区党群服务中心、老年大学各选 1 个点，10-30 人规模——不是“上线应用商店”

第二步 · 与适老化改造对接工信部适老化专项行动已推动 3092 家网站和 App 完成改造；我们补的正是官方点名的“**精准适配不足**”那一层形态决定不需要推广老人端不换手机、不换 App、零学习成本；家人端零安装。触达成本远低于需要老人重新学习的产品

如实说明：以上是路径设计，**尚无任何一个点位的实际合作**——我们不写“预计覆盖 X 万用户”这类无依据的数字。

收尾题 · 很多学生项目在这里丢分

会。而且不取决于名次

先补人

完成 5–8 位老人的任务式可用性测试，**公开报告结果**——包括没做到的

再补证据层

把证据层核验按“只读 → 改变类”的顺序分批接入主流程，每一步由回归断言守护

然后补动态页面

把页面版本校验与修复预算解耦，让高动态首页从“失败”变为“能办成”

这是我们的技术主张决定的：把“可信”做成架构约束，而不是提示词里的请求。

——架构约束不是比赛材料，它得一直维护下去。