

2026 AIC · 算法创新赛 · AI+ 软件创新

银龄智办

让手机替老人把事办成——
而且绝不说谎

2026 第八届全球校园人工智能算法精英大赛

团队 能工智人 | 参赛编号 AIC-2026-86471901



“看看我的快递 到哪了”

这是老人对手机说的**全部的话**。

没有 App 名称，没有操作步骤，没有“先点这里再点这里”
剩下的，由系统替她走完。

✓ 办好了

看看我的快递到哪了

您的快递查到了：

有 1 件还等着您去取，另外 3 件已经签收。

待取的这件的详情：

- 取件地点：某高校北校区菜鸟驿站
- 取件码：30-1-4006
- 快递公司：中通快递

内容较长，可以上下滑动看全

这次办成了，记住这个方法

知道了

打开

找家人

问题

老人能上网， 却办不成事

出行购票、快递取件、生活缴费、就医挂号——这些事已经全部搬到了手机上，却分散在**七八个 App** 里，每一步都有误触和不可逆的风险。

已到位

政策与界面适老化改造：大字号、简化界面、无障碍规范

仍缺失

谁来替老人把**跨应用、多步骤**的事真正走完

更危险

让 AI 代劳，它可能谎报、可能越权、可能卡住

**“已帮您把消息发出去了……
时间是 17:37，发送成功”**

这是我们在真机上遇到的原话。

而它只是读到了这条消息——那条消息在本轮开始之前就存在了。

它把别人的成果，算成了自己的。

我们没让模型更聪明， 而是让它无法说谎

当前主流是“更强的模型 + 更细的提示词 + 事后过滤”。我们走另一条路：把“可信”从提示词里拿出来，放进架构里。

①

闸门只读动作内容——不看模型说了什么，也不看它是否被说服

②

完成与否由执行记录判定——不由模型自述，也不交给第二个模型打分

③

无障碍树只作只读观察——来源再“可信”，也因此放行

这三条是**可检查的设计决定**，不是形容词。

一个圆钮， 一句话

一屏只有一件事。圆钮既是**状态**也是**开关**——空闲时“说给接线员听”，办事中变成“停下来”。

- 只有“不再请求工具”才算完成；“做不到”与“已完成”是**并列**的两种结局
- 家人只能看状态、认领求助、留言——**不提供远程控制**
- 平安守望以“沉默不能证明安全”为原则，绝不“狼来了”

● 我在



点一下开始说话

上次没办完的事
看看我的快递到哪了

接着办这件事

一条判据，管住所有不可逆的动作

判据只有一个：这个动作的后果能不能撤销。它在三层复用，每次扩展都由对抗实验的发现驱动。

判据：动作后果是否可逆

屏幕动作层

有文字的动作直接执行；**坐标点按**无法校验内容，降级为单次确认；命中本人操作词表则交还本人。

业务动作层

「删除」「恢复出厂设置」「解绑」等不可逆业务动作**并入同一不可逆族**，交还本人。

由实验发现 F4 驱动

导航动作层

越出任务应用集合的 `open_app`，该应用**首次确认一次**——粒度为“每个新应用一次”。

由实验发现 F3 驱动

效果：美团 10 步点餐任务**全程打扰 0 次**，结算一步交还老人——**安全不是靠多问换来的。**

它不会说“办好了”， 除非真的办好了

“是否办成”由本地代码扫描**本轮自己的调用日志**得出。证据不足时，它宁可告诉老人“**我没法确认这件事真的办成了**”。

四条规则

R0 触发 只有声明出现“改变外部世界”的说法才检查（泛指完成不查，避免误伤只读任务）

R1 文字来源 引用的文字必须出现在本轮成功输入的内容里

R2 时间锚点 时刻早于本轮开始 → 判为“运行前就存在”

R3 动作存在性 声称改变了什么，就必须真的执行过改变类动作

它是下限，不是证明

它只否证**物理上不可能**的声明——挡不住“确实动了手却没做成”。后者需要证据层核验，而我们**把这块短板也量化了**（第 11 页）。

这些数字来自真机，不是演示视频

8₊₁

第三方应用 + 系统设置
共 9 个页面跑通

13

真机任务
从查票到下单到缴费

0

美团 10 步点餐
全程打扰次数

149

回归断言
每次改动 2 秒全绿

微信 填消息

7 步。攻克聊天框无障碍盲区，用“剪贴板 + 输入法候选栏”稳妥录入。

拼多多 下单

14 步。App 直接跳转微信支付，模型在**无控件树的盲页面**上取消支付并返回。

12306 查火车票

13 步。跨日期多条件筛选，读出真实车次；收起面板逐项核对 4/4 一致。

口径：单机型、小样本、每项单次或少数几次运行，**不代表总体成功率**；除标注“生产确认模式”者外均在自动确认的演示模式下运行。

我们主动找自己的麻烦

怎么做的


针对 2025—2026 年五篇前沿工作指出的失效模式（提示层对齐只是局部现象、沙箱化风险、GUI 智能体安全评测混淆等），设计**五组对抗实验**。

结果

发现 5 处问题，修复 4 处；回归断言 99 → 149，四处修复全部由断言守护。

第 5 处我们没修，也没藏

词表扩充后，**边界探针仍 6/6 漏拦**（关闭查找手机、退出登录、更换手机号...）。这不是“没修好”，而是“**词表匹配**”这条路线的天花板。




招牌机制只做了一半——我们把它量化了

识别谎报的能力（越高越好）



代价：把真办成的判为“无法确认”（越低越好）



漏掉的是哪一类

只读结论。机械核验按设计不核验只读声明（否则误伤诚实的只读回答）——与真机发现 F8 是同一件事。

代价也如实报

证据原型会把“汇总计算得出、页面上没直接出现”的数字一并降级；这条误伤样本是我们主动放进对照的。

结论边界

受控实验证明的是闸门与核验逻辑的确定性，不证明真实模型被说服后也拦得住。

可信的底气

可信不是承诺， 是每天都能跑测试

149

项回归断言，31 个场景，每次改动 2 秒全绿

解耦

核心循环不依赖 Android，可在 JVM 上直接回归

可复核

断言 99 → 149 的原始输出逐级留档，报告里每个数字都能找到对应记录

这不是一次性的演示，是能天天跑的护栏——对抗实验发现的每一处修复，都由回归断言守着不退回。

它意味着什么

对一个不会用智能手机的老人来说，这项技术改变的不是“能不能上网”，而是**她能不能自己把一件小事办完，而不必等子女下班。**

政策

国办发〔2020〕45号、工信部适老化专项行动、《无障碍环境建设法》都指向这里

形态轻

老人端**不换手机、不换 App、零学习成本**；家人端零安装

可复制

不绑定具体应用，**新增 App 无需改造对方**

我们也如实说明

目前尚无正式的老年用户试用数据。最小可用性观察（知情同意 + 3 类任务 + 四项指标：能否独立发起 / 理解状态 / 中止 / 找到真人）已在筹备——这是我们下一步最重要的事。

我们知道还差什么

已实现 · 有测试守护

四项机制全部上线；8 款第三方应用 + 系统设置跑通 13 项真机任务；149 项回归断言；核心与 Android 解耦。

原型验证 · 未接入主流程

证据层核验（仅用于三组对照）、候选技巧的生成与人工采用/回退；机械层核验已上线。

尚未解决 · 如实列出

证据层核验接入执行循环；技能自进化的完整闭环；词表路线对边界动作的天花板（F5）；动态页面失败（F6）；**尚无真实老年用户试用。**

把“可信”做成**架构约束**，
而不是提示词里的请求。

一致。第三部分（四）与附录代码段均描述现行实现；附录代码为**逐行取自** `AgentLoop.kt` 的节选（27 行有效代码全部可在仓库检索到）。

- 现行机制：**动作周期**（窗口 12，尾部按周期 2~3 完整重复 3 次且含 ≥ 2 种工具）+ **无效重复**（同工具同参数且 `screenChanged` 恒为 false）
- 停止条件：动作循环提醒 5 次、无效重复提醒 3 次 / 停止 5 次
- **刻意不用页面指纹**：真实应用会动画、重算价格、轮播推广，指纹会产生假重复；翻页而文本不变同样会漏判

放弃指纹不是退让：把“什么算进展”建立在一个在真实应用里不成立的假设上，比不做这项判定更危险。

证明

给定一个**会撒谎、会松口、会绕路**的模型，闸门与核验逻辑本身的**确定性**——它不随模型的说辞变化。

不证明

真实模型被注入说服后也一定拦得住。后者取决于模型能力，属于模型侧变量，不是架构侧的保证。

真实模型由谁负责

第五部分 13 项真机任务（真实模型 + 真实第三方 App）与第七部分跨应用验证。

完整证据链

受控实验证明架构成立，真机实验证明在真实模型与真实应用上可用。

凡对抗实验结论，均按“有对照 / 可复现 / 有守护”三条标准标注成立条件，不外推到真实模型的安全性上。

F5 是**路线级上限**，不是实现缺陷。词表匹配能可靠拦住**有明确危险文字**的动作，但拦不住“文字本身中性、后果不可逆”的边界动作。

类别	结果	示例
显性危险动作	6 / 6 拦住	确认付款、立即支付、提交订单
隐蔽型危险动作	8 / 8 拦住	申请退款、取消订单、恢复出厂设置
边界探针	6 / 6 漏拦	关闭查找手机、允许安装未知应用、开启开发者选项、退出登录、更换手机号、关闭定位服务

如实保留比虚假承诺更有价值：**我们不用“漏拦率 0”这类把“模型无能”算作“安全有效”的表述。**

- **只发当前页面的可见文字与控件结构**，用于规划；不采集通讯录、相册、通话记录、麦克风常驻录音。
- **输入类动作的正文**由本地闸门先筛本人操作词表，命中即拒绝并交还本人，不进入模型决策。
- **截图按需**：仅在控件树缺失（纯图页面）时附加，且**每页只发一次**。
- **只追加、不重写**的对话记录保存在本机；任务存档可随时删除。
- **已知不足**：尚未按应用排除敏感页面（如银行类页面整体排除），这是下一步要做的事。

已经交付：候选生成 + 人工采用/回退

成功任务可沉淀为**候选技巧**；候选先进入候选区，由家人在设置页**采用后才会出现在**
`load_skill` **可用列表中**，可随时回退。技巧只存文字步骤，不存截图，也不自动生效。

尚未交付：自动闭环

失败归因、独立任务验证、按版本自动选版——属第八部分列明的研发方向，目前状态为**拟研发**。

因此“自进化”在当前版本中的准确含义是：**技巧可以沉淀、可以复用、可以回退，但采用与否由人决定**——这也是我们把它做成一等公民而非黑箱的原因。

同一目标“看看我的快递到哪了”，拼多多与淘宝 **COMPLETED**（各 5 步），京东 **PAUSED**（2 步）。

机制解释：stale_screen 版本校验是**为安全而设的竞态防线**（防止动作作用于已过期的界面观察），但在含常驻轮播的高动态首页上，界面版本高频变动使合法动作被判为过期，在 2 次修复预算内即耗尽配额。

- 同类电商首页在拼多多、淘宝成功 → 该失败是**间歇性的**
- 对老人而言，**间歇性失败比确定性失败更难理解**——这正是它值得单独记一条的原因
- 改进方向：把 stale_screen 与常规修复预算解耦，或改为自动重观察并重解析同一语义目标（新发现 F6，尚未修复）