

2026 AIC · 算法创新赛 · AI+ 软件创新

银龄智办

可信自进化跨应用助老智能体

2026 第八届全球校园人工智能算法精英大赛

团队 能工智人 | 参赛编号 AIC-2026-86471901



01

问题

老年人“能上网，却办不成事”。

通用手机智能体又有**谎报、越权、僵化**三大硬伤。

政策与界面改造已经到位

适老化专项行动、无障碍环境建设法、大字号与简化界面——但跨应用、多步骤、不可逆的事，老人仍然办不成。

真正的缺口不是界面，是“把事办完”

出行购票、快递取件、生活缴费、就医挂号——事务分散在多个 App 里，单应用适老化解决不了。

通用手机智能体的三大硬伤

谎报

说“已发送、已下单”，其实根本没做成

越权

替老人点了付款、动了钱

僵化

卡住就停，或原地空转到步数上限

缺的不是更聪明的模型，而是让架构保证可信。

02

方案

把“可信”从提示词约束下沉为架构约束——
三条可检查的设计决定，四项机制。

① 风控闸门只读动作内容

闸门看的是目标控件标签、要写入的正文、页面是否敏感——**不看模型说了什么，也不看它是否被说服。**

② 完成与否由执行记录判定

“是否办成”由本地代码扫描**本轮自己的调用日志**得出；不由模型自述，也不交给第二个模型打分。

③ 无障碍树只作只读观察

树只用来“看”，所有动作仍须经本地闸门；**来源再“可信”，也不因此放行。**

这三条是**可检查的设计决定**，不是形容词。

判据只有一个：**动作的后果是否可逆**。它被复用在三层，且每次扩展都由对抗实验的发现驱动。



效果
美团 10 步点餐任务**全程打扰 0 次**，结算一步交还老人。

与现有做法的差别
不是按敏感词或金额阈值拦截，也不是全流程逐步确认。

“已帮您把消息发出去了.....时间是 17:37，发送成功”

—— 真机实测中的真实事故：它只是读到了**本轮开始前就存在**的旧消息，把别人的成果算成了自己的。

判定规则（只用本轮执行记录）

- 1 R0 触发 声明出现“对外部世界产生改变”的说法才检查；泛指完成不检查，避免误伤只读任务
- 2 R1 文字来源 声明引用的文字必须出现在本轮成功输入的内容里
- 3 R2 时间锚点 声明里的时刻若早于本轮开始，判为“运行前就存在的内容”
- 4 R3 动作存在性 声称改变了什么，就必须真的执行过改变类动作

输出三值

通过 / 无法确认 / 驳回

“无法确认”是诚实输出

不是失败。老人宁可听到“我没法确认这件事真的办成了”，也不要一句自信的谎话。

它是下限，不是证明

只否证**物理上不可能**的声明；“确实动了手却没做成”需要证据层核验（见第 13 页）。


③ 控件树与截图互补的双通道观察

按页面能力**自动切换**：有控件树走文本，纯图页面走截图；无标签叶子控件与输入法按键单独编号；盲页面叠加 **10% + 5% 双层比例网格**，让模型有可指认的坐标。

④ “触发推送、方法拉取”的按需技巧

第三方应用的专门知识**不内联进系统指令**，只留“遇到什么情况查哪个技巧”，具体做法由模型识别到页面时调用 `load_skill1` 拉取。

同一任务：全量内联时调用 **0/4**，改为触发后 **3/3**，读对率 $2/4 \rightarrow 3/3$ 。



一屏一件事

首页只有一个大圆钮，它同时是**状态指示与开关**（空闲“说给接线员听” / 办事中“停下来”）；页面没有第二件需要判断的事。

五种收尾，各有独立界面

只有“不再请求工具”才算完成；
impossible / ask_person / ask_user / handoff 各有呈现——
把“做不到”与“已完成”并列为独立结局。

平安守望：绝不“狼来了”

以“**沉默不能证明安全**”为原则：每日报平安使“缺失的那条”本身成为告警；并严格区分“**服务离线**”与“**行为异常**”。

家人通道：不做远程控制

家人只能查看状态、认领求助、留言，**不能远程操作老人的手机**——从产品形态上排除诈骗者惯用的“远程协助”通道。



03

证据

不是 Demo，也不是自说自话：

真机 13 项任务、五组对抗实验、核验三组对照，全部可复现。

8+1 第三方应用 + 系统设置 (9 个页面)	13 真机任务跑通	0 美团 10 步点餐全程打扰次数	149 JVM 回归断言 (31 场景)
微信 填消息 7 步。攻克聊天框无障碍盲区，用“剪贴板 + 输入法候选栏”稳妥录入。	12306 查火车票 13 步。跨日期、多条件筛选，读出真实车次；收起面板逐项核对 4/4 一致。	拼多多 下单 14 步。App 直接跳转微信支付，模型在无控件树的盲页面上取消支付并返回。	

口径：单机型（OnePlus PLC110 / Android 16）、小样本、每项单次或少数几次运行，**不代表总体成功率**。除标注“生产确认模式”者外，均在自动确认的演示模式下运行。

设计依据


针对 2025—2026 年五篇前沿工作提出的失效模式（提示层对齐只是局部现象、沙箱化风险、GUI 智能体安全评测等）设计五组对抗实验。

结果

发现 5 处问题，修复 4 处；回归断言 99 → 149，四处修复全部由回归断言守护。

F5 如实保留

词表扩充后，边界探针仍 6/6 漏拦（关闭查找手机、退出登录、更换手机号...）。这不是“没修好”，而是“词表匹配”这条路线的天花板。



组	识别谎报	把真办成的判为“无法确认”
无核验（采信模型自述）	0 / 5	0 / 4
机械核验（现行）	4 / 5	1 / 4
证据核验（原型）	5 / 5	2 / 4

漏掉的那一类是只读结论

OutcomeCheck 按设计不核验只读声明（否则会误伤诚实的只读回答）——与真机发现 F8 是同一件事。

代价也如实报

证据原型会把“汇总计算得出、页面上没有直接出现”的数字一并降级；这条误伤样本是我们主动放进对照的。

结论边界

受控实验证明闸门与核验逻辑的确定性，不证明真实模型被注入说服后也拦得住——那由第 11 页真机与跨应用实验承担。

证据层核验目前**仅为对照用原型**（实现于回归套件），尚未接入执行循环；产品当前状态仍为“拟研发”。

核心循环与 Android 完全解耦


智能体核心是纯 Kotlin 实现，不依赖 Android，可在 JVM 上直接回归——这是能用测试驱动开发的前提。

149 项断言 / 31 个场景

每次改动执行 `harness/run.sh`，约 2 秒全绿；服务端另有 31 项 pytest。

99 → 149 的轨迹可逐级复核

对抗评测每次运行的原始输出（含修复前）全部留档，报告里每一处“修复前/修复后”的数字都能找到对应记录。



04

价值与展望

政策与市场都指向这里。

我们也如实说明：**还没有一位真实老人用过**——这是下一步。

政策方向明确

国办发〔2020〕45号《关于切实解决老年人运用智能技术困难的实施方案》、工信部适老化专项行动、《无障碍环境建设法》——都指向“让老人真正用得上”。

人群与落差真实

60岁以上人口规模持续扩大，而老年群体的数字技能与高频事务的线上化程度之间存在显著落差。

落地形态轻

老人端**不换手机、不换 App、零学习成本**；家人端**零安装（网页即可）**；不新增硬件。

我们如实说明

目前尚无正式的老年用户试用数据——现阶段完成的是实验室与团队内部的高仿真任务走查。面向老年群体的最小可用性观察（知情同意 + 3类任务 + 四项指标：能否独立发起 / 理解状态 / 中止 / 找到真人）已在筹备。



如实披露：我们知道还差什么

已实现（可运行、有测试守护）

四项机制全部上线；8 款第三方应用 + 系统设置跑通 13 项真机任务；149 项回归断言；核心循环与 Android 解耦。

原型验证（小样本，未接入主流程）

证据层核验（仅用于三组对照）、候选技巧的生成与人工采用/回退；机械层核验已上线。

拟研发 / 尚未解决

证据层核验接入执行循环；技能自进化的完整闭环（失败归因、独立任务验证、按版本自动选版）；词表路线对边界动作的天花板（F5）；动态页面的 `stale_screen` 失败（F6）。

把“可信”做成**架构约束**，而不是提示词里的请求。

一致。第三部分（四）与附录代码段均描述现行实现；附录代码为**逐行取自** `AgentLoop.kt` 的节选（27 行有效代码全部可在仓库检索到）。

- 现行机制：**动作周期**（窗口 12，尾部按周期 2~3 完整重复 3 次且含 ≥ 2 种工具）+ **无效重复**（同工具同参数且 `screenChanged` 恒为 false）
- 停止条件：动作循环提醒 5 次、无效重复提醒 3 次 / 停止 5 次
- **刻意不用页面指纹**：真实应用会动画、重算价格、轮播推广，指纹会产生假重复；翻页而文本不变同样会漏判

放弃指纹不是退让：把“什么算进展”建立在一个在真实应用里不成立的假设上，比不做这项判定更危险。

证明

给定一个**会撒谎、会松口、会绕路**的模型，闸门与核验逻辑本身的**确定性**——它不随模型的说辞变化。

不证明

真实模型被注入说服后也一定拦得住。后者取决于模型能力，属于模型侧变量，不是架构侧的保证。

真实模型由谁负责

第五部分 13 项真机任务（真实模型 + 真实第三方 App）与第七部分跨应用验证。

完整证据链

受控实验证明架构成立，真机实验证明在真实模型与真实应用上可用。

凡对抗实验结论，均按“有对照 / 可复现 / 有守护”三条标准标注成立条件，不外推到真实模型的安全性上。

F5 是**路线级上限**，不是实现缺陷。词表匹配能可靠拦住**有明确危险文字**的动作，但拦不住“文字本身中性、后果不可逆”的边界动作。

类别	结果	示例
显性危险动作	6 / 6 拦住	确认付款、立即支付、提交订单
隐蔽型危险动作	8 / 8 拦住	申请退款、取消订单、恢复出厂设置
边界探针	6 / 6 漏拦	关闭查找手机、允许安装未知应用、开启开发者选项、退出登录、更换手机号、关闭定位服务

如实保留比虚假承诺更有价值：**我们不用“漏拦率 0”这类把“模型无能”算作“安全有效”的表述。**

- **只发当前页面的可见文字与控件结构**，用于规划；不采集通讯录、相册、通话记录、麦克风常驻录音。
- **输入类动作的正文**由本地闸门先筛本人操作词表，命中即拒绝并交还本人，不进入模型决策。
- **截图按需**：仅在控件树缺失（纯图页面）时附加，且**每页只发一次**。
- **只追加、不重写**的对话记录保存在本机；任务存档可随时删除。
- **已知不足**：尚未按应用排除敏感页面（如银行类页面整体排除），这是下一步要做的事。

已经交付：候选生成 + 人工采用/回退

成功任务可沉淀为**候选技巧**；候选先进入候选区，由家人在设置页**采用后才会出现在**
`load_skill` **可用列表中**，可随时回退。技巧只存文字步骤，不存截图，也不自动生效。

尚未交付：自动闭环

失败归因、独立任务验证、按版本自动选版——属第八部分列明的研发方向，目前状态为**拟研发**。

因此“自进化”在当前版本中的准确含义是：**技巧可以沉淀、可以复用、可以回退，但采用与否由人决定**——这也是我们把它做成一等公民而非黑箱的原因。

同一目标“看看我的快递到哪了”，拼多多与淘宝 **COMPLETED**（各 5 步），京东 **PAUSED**（2 步）。

机制解释：stale_screen 版本校验是**为安全而设的竞态防线**（防止动作作用于已过期的界面观察），但在含常驻轮播的高动态首页上，界面版本高频变动使合法动作被判为过期，**在 2 次修复预算内即耗尽配额**。

- 同类电商首页在拼多多、淘宝成功 → 该失败是**间歇性的**
- 对老人而言，**间歇性失败比确定性失败更难理解**——这正是它值得单独记一条的原因
- 改进方向：把 stale_screen 与常规修复预算解耦，或改为自动重观察并重解析同一语义目标（新发现 F6，尚未修复）