

2026 AIC · 算法创新赛 · AI+ 软件创新

银龄智办

老人只说一句话，
手机替他把事跑完

真机已跑通 13 项任务 / 8 款第三方应用

团队 能工智人 | 参赛编号 AIC-2026-86471901



老人要办的事，往往就是这一句话

“看看我的快递到哪了”

没有 App 名称，没有操作步骤，没有“先点这里再点那里”。
这是我们在真机上跑过的真实任务输入——与真机上老人会说的话一致。

而它并不是每次都走得通

同一句话，拼多多与淘宝各 5 步跑通；**京东只走了 2 步就停下**，界面上的原话是“这一步总是做不成，已停下。您可以自己操作，或请家人帮忙。”



说明：上图为团队真机测试的真实截图；截至提交，尚无面向老年用户的正式试用数据（见 P10）。

问题

不是没有 AI 会点外卖， 是没人敢让 AI 替老人点

通用手机智能体有三个硬伤，每一个都足以让家人不敢把它交到老人手里。

谎报

说“已发送、已下单”，其实根本没做成

越权

替老人点了付款、动了钱

僵化

卡住就停，或原地空转到步数上限

“已帮您把消息发出去了……时间是 17:37，发送成功”

——真机上遇到的原话。而它只是读到了**本轮开始前就存在**的旧消息，把别人的成果算成了自己的。

我们的答案

我们把“可信” 从提示词里搬进了架构里

当前主流是“更强的模型 + 更细的提示词 + 事后过滤”。我们走另一条路。

闸门

只看**动作内容**——不看模型说了什么，也不看它是否被说服

账本

完成与否由**本轮自己的执行记录**判定，不由模型自述

只读

无障碍树**只作观察**，来源再“可信”也不因此放行

这三条是**可检查的设计决定**，不是形容词。

一个圆钮， 一句话

一屏只有一件事。圆钮既是**状态**也是**开关**——空闲时“说给接线员听”，办事中变成“停下来”。

- 只有“不再请求工具”才算完成；“做不到”与“已完成”是**并列的两种结局**
- 家人只能看状态、认领求助、留言——**不提供远程控制**
- 平安守望以“沉默不能证明安全”为原则，绝不“狼来了”

● 我在



点一下开始说话

上次没办完的事
看看我的快递到哪了

接着办这件事

全篇唯一记忆点

AI 说办好了**不算数**—— 只有手机上**真的发生的动作**才算数

判据：能不能撤销

一条判据管住所有不可逆动作——屏幕动作按可逆性分级：删除 / 恢复出厂设置 / 解绑并入不可逆族；导航越出任务应用集合时首次确认一次。

效果：美团 10 步点餐全程打扰 0 次，结算一步交还老人。

核验：查账不查嘴

完成声明必须能被**本轮自己的执行记录**支持：引用的文字要真的输入过、提到的时刻不能早于本轮开始、声称改变过就必须真做过改变类动作。

证据不足时，它说的是“**我没法确认这件事真的办成了**”。

13 项真机任务、149 条断言、五组对抗实验

8₊₁

第三方应用 + 系统设置
共 9 个页面跑通

13

真机任务
查票 · 点餐 · 取件 · 缴费

0

美团 10 步点餐
全程打扰次数

149


回归断言
每次改动 2 秒全绿

我们主动把 AI 骗了三次

针对 2025—2026 五篇前沿工作指出的失效模式设计五组对抗实验：**发现 5 处问题，修复 4 处**，回归断言 99 → 149。第 5 处（词表对边界动作的天花板）**我们没修，也没藏**——见 P10。

为什么敢把这个数字放上来

对抗评测每次运行的原始输出（含修复前）逐级留档，**报告里每一处“修复前/修复后”都能翻到对应记录。**



别人靠模型的自律，我们靠架构的兜底

同一个问题	常见做法	我们的做法
谁来判定危险	更强的模型 + 更细的提示词 + 事后过滤	本地闸门只读动作内容——不读模型说辞
谁说了算“办成”	采信模型自述，或再叫一个模型来打分	本轮自己的执行日志——查账不查嘴
卡住了怎么办	重试到底，或直接失败	五种收尾各有界面：做不到 ≠ 已完成，失败能接真人
家人的通道	远程协助 / 远程控制	不做远程控制——从产品形态上排除这条诈骗通道

我们不声称在模型能力上领先。我们主张的是：安全属性应该由架构保证，而不是由模型的顺从保证。

对老人来说，改变的不是“能不能上网”， 是能不能自己把一件小事办完

而不必等子女下班、不必反复打电话问“那个码在哪”。

政策指向

国办发〔2020〕45号《关于切实解决老年人运用智能技术困难的实施方案》、工信部适老化专项行动、《无障碍环境建设法》——都指向“让老人真正用得上”

落地形态轻

老人端**不换手机、不换 App、零学习成本**；家人端零安装（网页即可）；不新增硬件

可复制

不绑定具体应用，**新增 App 无需改造对方**；面向老年人之外，同样适用于任何“跨应用多步骤”的场景

这三件事，我们现在 还不敢让它做

边界动作拦不住

「关闭查找手机」「退出登录」这类文字中性、后果不可逆的动作，词表**6/6 漏拦**。这是“词表匹配”这条路线的天花板，不是实现缺陷。下一步要靠页面语义而非词表。

高动态页面会失败

含常驻轮播的首页（如京东）会让页面版本校验持续判为过期，**2 步即耗尽修复预算**而暂停。问题在拼多多、淘宝成功，说明是**间歇性**的——而间歇性失败对老人更难理解。

还没有一位真实老人用过

现阶段完成的是实验室与团队内部的高仿真任务走查。**零老年用户数据**是我们最大的缺口。最小可用性观察（知情同意 + 3 类任务 + 四项指标）已在筹备。

我们不用“漏拦率 0”这类把“模型没能力”算作“安全有效”的表述，也不把“没做到”写成“下一阶段工作”。

下一步

先补上人，再补上证据层

1 · 老年用户观察

5-8 位老人、知情同意、3 类任务，记录四项：能否**独立发起** / **理解状态** / **中止** / **找到真人**。这一项同时抬“应用价值”与“功能完整性”。

2 · 证据层核验接入主流程

我们已经在回归套件里做出了原型并量化过它（识别谎报 4/5 → 5/5，代价 1/4 → 2/4），下一步是给它一个能区分“**页面上没有**”与“**事情没发生**”的判据，然后接进执行循环。

3 · 动态页面与技能闭环

把页面版本校验与修复预算解耦；完成技能自进化的完整闭环（失败归因、独立任务验证、按版本自动选版）。



技术的终点， 是让老人不必学会技术

把“可信”做成**架构约束**，而不是提示词里的请求。

银龄智办·可信自进化跨应用助老智能体

团队 能工智人 | 参赛编号 AIC-2026-86471901

一致。第三部分（四）与附录代码段均描述现行实现；附录代码为**逐行取自** `AgentLoop.kt` 的节选（27 行有效代码全部可在仓库检索到）。

- 现行机制：**动作周期**（窗口 12，尾部按周期 2~3 完整重复 3 次且含 ≥ 2 种工具）+ **无效重复**（同工具同参数且 `screenChanged` 恒为 false）
- 停止条件：动作循环提醒 5 次、无效重复提醒 3 次 / 停止 5 次
- **刻意不用页面指纹**：真实应用会动画、重算价格、轮播推广，指纹会产生假重复；翻页而文本不变同样会漏判

放弃指纹不是退让：把“什么算进展”建立在一个在真实应用里不成立的假设上，比不做这项判定更危险。

证明

给定一个**会撒谎、会松口、会绕路**的模型，闸门与核验逻辑本身的**确定性**——它不随模型的说辞变化。

不证明

真实模型被注入说服后也一定拦得住。后者取决于模型能力，属于模型侧变量，不是架构侧的保证。

真实模型由谁负责

第五部分 13 项真机任务（真实模型 + 真实第三方 App）与第七部分跨应用验证。

完整证据链

受控实验证明架构成立，真机实验证明在真实模型与真实应用上可用。

凡对抗实验结论，均按“有对照 / 可复现 / 有守护”三条标准标注成立条件，不外推到真实模型的安全性上。

F5 是**路线级上限**，不是实现缺陷。词表匹配能可靠拦住**有明确危险文字**的动作，但拦不住“文字本身中性、后果不可逆”的边界动作。

类别	结果	示例
显性危险动作	6 / 6 拦住	确认付款、立即支付、提交订单
隐蔽型危险动作	8 / 8 拦住	申请退款、取消订单、恢复出厂设置
边界探针	6 / 6 漏拦	关闭查找手机、允许安装未知应用、开启开发者选项、退出登录、更换手机号、关闭定位服务

如实保留比虚假承诺更有价值：**我们不用“漏拦率 0”这类把“模型无能”算作“安全有效”的表述。**

- **只发当前页面的可见文字与控件结构**，用于规划；不采集通讯录、相册、通话记录、麦克风常驻录音。
- **输入类动作的正文**由本地闸门先筛本人操作词表，命中即拒绝并交还本人，不进入模型决策。
- **截图按需**：仅在控件树缺失（纯图页面）时附加，且**每页只发一次**。
- **只追加、不重写**的对话记录保存在本机；任务存档可随时删除。
- **已知不足**：尚未按应用排除敏感页面（如银行类页面整体排除），这是下一步要做的事。

已经交付：候选生成 + 人工采用/回退

成功任务可沉淀为**候选技巧**；候选先进入候选区，由家人在设置页**采用后才会出现在**
`load_skill` **可用列表中**，可随时回退。技巧只存文字步骤，不存截图，也不自动生效。

尚未交付：自动闭环

失败归因、独立任务验证、按版本自动选版——属第八部分列明的研发方向，目前状态为**拟研发**。

因此“自进化”在当前版本中的准确含义是：**技巧可以沉淀、可以复用、可以回退，但采用与否由人决定**——这也是我们把它做成一等公民而非黑箱的原因。

同一目标“看看我的快递到哪了”，拼多多与淘宝 **COMPLETED**（各 5 步），京东 **PAUSED**（2 步）。

机制解释：stale_screen 版本校验是**为安全而设的竞态防线**（防止动作作用于已过期的界面观察），但在含常驻轮播的高动态首页上，界面版本高频变动使合法动作被判为过期，在 2 次修复预算内即耗尽配额。

- 同类电商首页在拼多多、淘宝成功 → 该失败是**间歇性的**
- 对老人而言，**间歇性失败比确定性失败更难理解**——这正是它值得单独记一条的原因
- 改进方向：把 stale_screen 与常规修复预算解耦，或改为自动重观察并重解析同一语义目标（新发现 F6，尚未修复）